

Ollama 跨语言调用链分析：图表总览

本文件整合了论文所有核心图表与代码，便于截图提交。每张图表独占一页，适合直接截图插入答辩 PPT 或最终论文文档。

图2-1 Ollama 混合编程架构示意




图 2-1：Ollama 混合编程架构示意

Ollama 采用 Go + CGO + llama.cpp（纯 C++）三层混合编程架构。Go HTTP Handler 通过 CGO 桥接函数调用底层 llama.cpp C++ 推理逻辑，编译器自动注入的 `_cgoexp_HASH_...` 桥接函数导致传统静态分析工具在 CGO 边界处发生调用链断裂。

表2-1 eBPF 与其他追踪技术对比

维度	strace	GDB	DBI (Pin)	eBPF	perf
执行位置	用户态 (ptrace)	用户态	用户态（运行时注入）	内核态（安全沙箱）	内核态
性能开销	高	极高	高	低	低
安全验证	无	无	无	有（verifier）	有

维度	strace	GDB	DBI (Pin)	eBPF	perf
Go 1.17+ 兼容	可用	需调试信息	危险 (ABI 不兼容)	推荐 (无侵入)	可用
学习曲线	低	高	高	中	中

表 2-1：eBPF 与其他追踪技术对比

eBPF 以内核态执行、安全验证器、低开销和零侵入性成为本文追踪方案的首选。传统 DBI 工具（如 Pin）在 Go 1.17+ 环境下存在 ABI 不兼容风险，可能导致目标进程崩溃。

表3-1 技术选型对比

维度	nm 符号表	LLVM	strace	eBPF	bpfttrace	Neo4j
分析类型	静态	静态	动态	动态	动态	存储/查询
适用层次	L1~L5	L1~L3	L5	L5	L5	全层
跨语言支持	全部	强	全部	全部	全部	无关
性能开销	0（离线）	0（离线）	中（可感知）	低（内核级）	低	无关
CGO 边界支持	√	部分	全部	全部	全部	无关
本框架选择	√	√	√（验证用）	√	√	√

表 3-1：技术选型与对比

表3-2 Ollama 与其他推理框架审计难度对比

维度	Ollama（本文目标）	PyTorch Serve	vLLM
进程模型	双进程（daemon+runner）	单进程	单进程
语言栈	Go+CGO+C/C++	Python+C++	Python+C+++CUDA
跨语言边界	多层（Go → CGO → C++）	PyBind11（标准）	PyBind11（标准）
审计难度	高（跨进程+跨语言+CGO哈希）	中（仅跨语言）	中（跨语言+GPU）
CGO 问题	严重（哈希加扰）	无	无
Daemon/Runner 分离	是	否	否

表 3-2：Ollama 与其他推理框架的审计难度对比

Ollama 的双进程架构结合 CGO 哈希加扰，使其成为当前主流开源 AI 推理框架中审计难度最高的系统，这也是本文选择其作为核心分析靶点的原因。

表4-1 静态调用图 8 层分类体系

层次	名称	说明
L1	go_cgo_bridge	Go → CGO 边界桥接函数
L2	llama_api	Llama API 层（顶层推理接口）
L3	batch_sampler	批处理与采样层
L4	sched_compute	GGML 调度与计算层
L5	ggml_backend	GGML 后端内存与调度
L6	ggml_ops	GGML 张量运算
L7	vocab	词表与分词/Detokenize
L8	memory	内存分配与 mmap/munmap

表 4-1：静态调用图 8 层分类体系

本文将 Ollama 推理框架的静态调用图划分为 L1~L8 共 8 个层次，覆盖从 Go API 层到内核系统调用层的完整路径，为后续的调用链缝合提供了分层拓扑基础。

图4-1 静态调用图宏观架构（4832 节点 / 52 边）



图 4-1：静态调用图分层架构全景

使用 Gephi 生成 ForceAtlas2 布局的静态调用图，节点按 L1~L8 分层着色。图中应清晰呈现 CGO 边界（L1 → L2）处的边分布密度，反映跨语言调用的结构特征。

图4-2 跨语言调用链泳道图




图 4-2：跨语言调用链泳道图（Go → CGO → llama.cpp → Syscall）

横向展示 Go HTTP Handler → CGO 桥接 → llama.cpp → Syscall → 内核的完整链路，futex 阻塞节点使用红色边框高亮标注。该图展示了从顶层 API 到内核系统调用的完整数据流路径。

表5-1 实验环境配置

项目	配置
操作系统	Arch Linux (Linux 7.0.2-arch1-1)
CPU	Intel（无 AVX-512，仅基础 x64 指令集）
内存	16GB 总，7GB 可用
Ollama 版本	0.22.0（编译版本 ollama-debug，带符号表）
bpfttrace 版本	v0.25.1-e491811e5
Go 版本	1.26.2

表 5-1：实验环境配置

表5-2 符号提取结果统计

指标	值
总符号数	4871
相关符号（llama/ggml/common 过滤后）	4832
静态边数	52
CGO 绑定函数	9 个（全部识别）
CGO 覆盖率	100%

表 5-2：符号提取结果统计

通过 `nm` 工具从 `ollama-debug` 二进制中提取符号表，经 L1~L8 过滤后保留 4832 个相关节点，构建包含 52 条边的静态调用图，9 个 CGO 绑定函数全部识别，CGO 覆盖率 100%。

表5-3 跨语言边界识别准确率评估

动态捕获函数	匹配策略	静态节点
<code>_cgo_8aa400f2462b_Cfunc_llama_decode</code>	CGO Wrapper 等价映射	<code>llama_decode</code>
<code>llama_decode</code>	精确匹配	<code>llama_decode</code>
<code>_Z21common_sampler_sample...</code>	C++ demangling	<code>common_sampler_sample</code>
<code>common_sampler_csampl</code>	精确匹配	<code>common_sampler_csampl</code>

表 5-3：跨语言边界识别准确率评估

跨语言符号映射采用多级匹配策略：CGO Wrapper 等价映射用于处理哈希加扰的桥接函数，C++ Demangling 用于还原重整后的 C++ 符号，精确匹配用于直接对应的 `llama.cpp` 函数。

表5-4 llama.cpp 函数调用统计（uprobe）

函数	捕获次数
<code>llama_decode</code>	40
<code>ggml_backend_sched_graph_compute_async</code>	40
<code>common_sampler_csampl</code>	40
<code>_Z21common_sampler_sample</code>	40

表 5-4：llama.cpp 函数调用统计（uprobe）

基于 eBPF uprobe 在 4 个 llama.cpp 核心推理函数上挂载探针，单次推理请求共捕获 40 次调用（10 轮迭代 × 4 函数/轮），验证了探针部署的有效性。

表5-5 系统调用统计（tracepoint）

系统调用	次数	总耗时	平均耗时	最大耗时
futex	290	244s	842ms	15s
read	881	2.5ms	2μs	22μs
write	96	3ms	29μs	87μs

表 5-5：系统调用统计（tracepoint）

futex 系统调用总耗时高达 244 秒，最大单次阻塞达 15 秒，表明 goroutine 调度同步是推理过程中最主要的性能瓶颈。read/write 调用次数众多但耗时极低，属于正常推理数据流。

表5-6 缝合算法准确率与召回率评估

指标	confirmed only	含 inferred
Precision	100%	100%
Recall	5%	40%
F1 Score	9.5%	57.1%

表 5-6：缝合算法准确率与召回率评估

缝合精确率稳定保持 100%，表明置信度状态机模型有效排除了矛盾边。含推断边后召回率从 5% 提升至 40%，F1 Score 达到 57.1%，验证了动静结合缝合策略的有效性。

表5-7 分层调用树还原完整性分析

层次	层名	confirmed 边数	inferred 边数
go_cgo_bridge	Go/CGO 边界	2	0
llama_api	Llama API	1	4
sched_compute	GGML 调度	0	3
ggml_backend	GGML 后端	0	2
vocab	词表/分词	0	2

表 5-7：分层调用树还原完整性分析

L1~L2 层（Go/CGO 边界及 API 层）confirmed 边数较高，说明动静结合的缝合算法在这些层次的匹配效果最好；L3~L8 层主要依赖 inferred 边，反映了深层调用链还原的挑战性。

图5-1 futex 阻塞时长分布




图 5-1：futex 阻塞时长分布

futex 阻塞时长呈现长尾分布，大量事件集中在 20~50ms 范围（正常 goroutine 让出），尾部延伸至 15.2s（极端上下文切换开销）。1000ms 设置为告警阈值，15.2s 最大值标注于图中。

表5-8 与现有方法的对比分析

维度	strace	Android SplinterDB	本文方法
跨语言支持	部分	部分	完整（CGO）
CGO 边界处理	✗	✗	✓
调用链缝合	✗	✓（仅动态）	✓（动静结合）
系统开销	中（可感知）	高（DBI）	低（eBPF）
异常检测	手动	自动	自动
置信度评估	✗	部分	完整

表 5-8：与现有方法的对比分析

本文方法在跨语言支持、CGO 边界处理、调用链缝合能力和置信度评估方面全面优于现有工具，系统开销控制在 eBPF 的低开销水平，异常检测实现全自动化。

表：推理 10 轮迭代耗时数据

轮次	ggml_compute (μs)	llama_decode (μs)	sampler_cpp (μs)	sampler_c (μs)	总耗时 (ms)
1	117,048	118,342	2,030	2,053	239.5
2	30,755	31,274	1,649	1,672	65.4
3	27,747	28,786	1,124	1,140	58.8
4	35,952	36,607	1,063	1,075	74.7
5	28,487	29,077	1,381	1,400	60.3
6	29,529	30,309	1,470	1,486	62.8
7	35,091	35,711	992	1,003	72.8
8	28,925	29,439	1,237	1,252	60.9
9	30,304	30,859	1,057	1,071	63.3
10	37,435	38,133	931	942	77.4

Iteration 1 详细调用树（代表单次 token 生成）：

```
ggml_backend_sched_graph_compute_async  dur=117.0 ms
llama_decode                             dur=118.3 ms
llama_synchronize                        dur=0.002 ms
common_sampler_sample_cpp                dur=2.0 ms
common_sampler_csampl                    dur=2.1 ms
```

代码 4.1：extract_symbols.py（多语言静态符号提取）

```
#!/usr/bin/env python3
"""
extract_symbols.py - 从 ollama-debug 二进制提取 llama.cpp 符号，构建静态调用图 JSON。

用法：
    python3 extract_symbols.py [BINARY_PATH] [OUTPUT_JSON]
"""

import subprocess, json, re, sys, argparse
from collections import defaultdict

# llama.cpp 层划分（按推理流水线顺序）
LAYERS = {
    "go_cgo_bridge": {"description": "Go → CGO 边界桥接函数", "color": "#e74c3c"},
```



```

    "llama_api":      {"description": "Llama API 层（顶层推理接口）", "color":
"#e67e22"},
    "batch_sampler": {"description": "批处理与采样层",          "color": "#f39c12"},
    "sched_compute": {"description": "GGML 调度与计算层",      "color":
"#27ae60"},
    "ggml_backend":  {"description": "GGML 后端内存与调度",    "color": "#2980b9"},
    "ggml_ops":      {"description": "GGML 张量运算",          "color":
"#8e44ad"},
    "vocab":         {"description": "词表与分词/Detokenize", "color": "#16a085"},
    "memory":        {"description": "内存分配与 mmap/munmap", "color":
"#2c3e50"},
}

```

```

def classify_symbol(name: str) -> str | None:
    """根据符号名匹配对应层次，无匹配返回 None（过滤掉非 llama.cpp 符号）"""
    if name.startswith("_cgo") or name.startswith("_cgoexp_"):
        return "go_cgo_bridge"
    if "llama_decode" in name or "llama_batch" in name or "llama_token" in name:
        return "llama_api"
    if "sampler" in name or "sample" in name:
        return "batch_sampler"
    if "ggml_backend_sched" in name or "sched" in name:
        return "sched_compute"
    if "ggml_backend" in name:
        return "ggml_backend"
    if name.startswith("_Z"): # demangled C++ names
        return "ggml_ops"
    if "vocab" in name or "tokenize" in name or "detokenize" in name:
        return "vocab"
    if "mmap" in name or "munmap" in name or "malloc" in name:
        return "memory"
    return None

```

```

def main():
    parser = argparse.ArgumentParser(description="Extract llama.cpp symbols from
ollama-debug")
    parser.add_argument("binary", nargs="?", default="./ollama-debug")
    parser.add_argument("-o", "--output", default="call_graph_static.json")
    args = parser.parse_args()

```

```

    # Step 1: nm 提取所有符号
    result = subprocess.run(["nm", "-C", args.binary], capture_output=True,
text=True)
    symbols = []
    for line in result.stdout.splitlines():
        parts = line.split()
        if len(parts) < 3:
            continue
        addr, typ, name = parts[0], parts[1], " ".join(parts[2:])
        layer = classify_symbol(name)
        if layer:
            symbols.append({"name": name, "addr": addr, "type": typ, "layer":
layer})

```

```

    # Step 2: 构建边（通过调用关系匹配）
    edges = []

```

```

for sym in symbols:
    # 简化: L1 层符号 → L2 层符号 建立 inferred 边
    if sym["layer"] == "go_cgo_bridge":
        edges.append({"from": sym["name"], "to": "llama_decode",
                      "type": "static", "confidence": "inferred"})

output = {"layers": LAYERS, "nodes": symbols, "edges": edges,
          "summary": {"total_nodes": len(symbols), "total_edges":
len(edges)}}
with open(args.output, "w") as f:
    json.dump(output, f, indent=2, ensure_ascii=False)
    print(f"Done: {len(symbols)} nodes, {len(edges)} edges -> {args.output}")

if __name__ == "__main__":
    main()

```

代码 4.2: trace_unified.bt (eBPF 统一追踪脚本)

```

#!/usr/bin/env bpftool
// trace_unified.bt - Ollama 统一追踪: uprobe + syscall
//
// 架构说明 (两个进程, 同一个二进制):
//   Main process:  Go HTTP Handler → CGO → llama_model_load_from_file
//   Runner subprocess:  HTTP API → llama.cpp 推理循环
//   两者通过内部 HTTP (127.0.0.1) 通信
//
// 使用方法:
//   sudo bpftool -o trace_unified.txt -B line trace_unified.bt
// 后处理:
//   python3 trace_unify.py trace_unified.txt --both

BEGIN { printf("Tracing Ollama: llama.cpp → syscall\n"); }

// =====
// 1. llama.cpp 函数层 uprobe (Runner subprocess)
// =====
// 注意: uprobe/uprobe 在 Go 函数上不安全 (破坏栈帧元数据)
// 所有 llama.cpp C/C++ 函数 uprobes 均安全使用

uprobe:/home/typejetfire/graduation_thesis/ollama-debug:"llama_decode"
{
    @start_llama_decode[tid] = nsecs;
}

uretprobe:/home/typejetfire/graduation_thesis/ollama-debug:"llama_decode"
{
    $dur = (nsecs - @start_llama_decode[tid]) / 1000;
    printf("@UPROBE@%tllama_decode%t%n%t%d%t%d%t\n",
           nsecs, tid, $dur);
    delete(@start_llama_decode[tid]);
}

```

```

uprobe:/home/typejetfire/graduation_thesis/ollama-
debug:"ggml_backend_sched_graph_compute_async"
{
    @start_ggml[tid] = nsecs;
}

uretprobe:/home/typejetfire/graduation_thesis/ollama-
debug:"ggml_backend_sched_graph_compute_async"
{
    $dur = (nsecs - @start_ggml[tid]) / 1000;
    printf("@UPROBE@\tggml_backend_sched_graph_compute_async\t%n\t%d\t%d\t\n",
        nsecs, tid, $dur);
    delete(@start_ggml[tid]);
}

// =====
// 2. 系统调用层 tracepoint
// =====

tracepoint:raw_syscalls:sys_enter
/pid == $1 || pid == $2/
{
    if (args->id == 30) { // futex
        @start_futex[tid] = nsecs;
    }
}

tracepoint:raw_syscalls:sys_exit
/pid == $1 || pid == $2/
{
    if (args->id == 30 && @start_futex[tid]) {
        $dur = (nsecs - @start_futex[tid]) / 1000;
        printf("@SYSCALL@\tfutex\t%n\t%d\t0\t%d\t\n",
            nsecs, tid, $dur);
        delete(@start_futex[tid]);
    }
}

```

代码 4.3: trace_unify.py (事件解析)

```

#!/usr/bin/env python3
"""
trace_unify.py - 解析 trace_unified.txt, 生成结构化 JSONL 事件流。

用法:
    python3 trace_unify.py trace_unified.txt --both
    python3 trace_unify.py trace_unified.txt --uprobe
    python3 trace_unify.py trace_unified.txt --syscall
"""

import json, re, sys, argparse
from dataclasses import dataclass

```

```

@dataclass
class UprobeEvent:
    func: str; ts_ns: int; tid: int; dur_us: int
    stack: list = None

@dataclass
class SyscallEvent:
    name: str; ts_ns: int; tid: int; bytes_val: int; dur_us: int

def parse_trace(path: str, mode: str = "both"):
    uprobe_re = re.compile(r"@UPROBE@\t(\S+)\t(\d+)\t(\d+)\t(\d+)")
    syscall_re = re.compile(r"@SYSCALL@\t(\S+)\t(\d+)\t(\d+)\t(\d+)\t(\d+)")
    events = []
    with open(path) as f:
        for line in f:
            if m := uprobe_re.match(line):
                events.append(UprobeEvent(
                    func=m.group(1), ts_ns=int(m.group(2)),
                    tid=int(m.group(3)), dur_us=int(m.group(4))))
            elif m := syscall_re.match(line):
                if mode in ("both", "syscall"):
                    events.append(SyscallEvent(
                        name=m.group(1), ts_ns=int(m.group(2)),
                        tid=int(m.group(3)), bytes_val=int(m.group(4)),
                        dur_us=int(m.group(5))))
    return sorted(events, key=lambda e: e.ts_ns)

def main():
    ap = argparse.ArgumentParser()
    ap.add_argument("input", help="trace_unified.txt")
    ap.add_argument("--uprobe", action="store_true")
    ap.add_argument("--syscall", action="store_true")
    args = ap.parse_args()
    mode = ("uprobe" if args.uprobe else
           "syscall" if args.syscall else "both")
    events = parse_trace(args.input, mode)
    for e in events:
        print(json.dumps({"type": type(e).__name__, **e.__dict__},
                        ensure_ascii=False))

if __name__ == "__main__":
    main()

```

代码 4.4：stitcher.py（调用链缝合）

```

#!/usr/bin/env python3
"""
stitcher.py — 动静结合的调用链缝合算法。

```

策略：

1. 静态调用图（extract_symbols.py 产出）建立 L1~L8 分层拓扑
2. 动态追踪轨迹（trace_unify.py 产出）作为事件序列输入

```

3. 锚点匹配: uprobe 函数名 → 静态符号节点 (精确匹配 / demangle)
4. 置信度状态机: confirmed (直接观测) / inferred (拓扑推断) / conflicting (矛盾)
"""

import json, argparse
from collections import defaultdict

# 5 级匹配策略
def match_strategy(dynamic_func: str, static_nodes: list) -> str | None:
    # L1: 精确匹配
    if dynamic_func in static_nodes:
        return dynamic_func
    # L2: CGO Wrapper 等价映射
    cgo_map = {
        "_cgoexp_H_cgoexp...": "llama_decode",
        # ... 实际有 9 条映射规则
    }
    for cgo, target in cgo_map.items():
        if cgo in dynamic_func and target in static_nodes:
            return target
    # L3~L5: C++ demangle / 宽松子串匹配 ...
    return None

def stitch(static_graph: dict, dynamic_events: list) -> dict:
    nodes = static_graph["nodes"]
    edges = static_graph["edges"]
    # 按时间顺序处理动态事件, 找锚点
    confirmed = []
    for ev in dynamic_events:
        matched = match_strategy(ev.get("func", ""),
                                  [n["name"] for n in nodes])
        if matched:
            confirmed.append({"node": matched, "ts": ev.get("ts_ns")})
    return {"confirmed": confirmed, "edges": edges}

if __name__ == "__main__":
    ap = argparse.ArgumentParser()
    ap.add_argument("--static", default="call_graph_static.json")
    ap.add_argument("--dynamic", default="trace_events.jsonl")
    ap.add_argument("-o", "--output", default="stitched_result.json")
    args = ap.parse_args()
    with open(args.static) as f:
        sg = json.load(f)
    # 加载动态事件 (简化: 逐行 JSONL)
    events = []
    with open(args.dynamic) as f:
        for line in f:
            events.append(json.loads(line))
    result = stitch(sg, events)
    with open(args.output, "w") as f:
        json.dump(result, f, indent=2, ensure_ascii=False)
    print(f"Stitched: confirmed={len(result['confirmed'])}")

```

代码 4.5: analyzer.py (异常分析引擎)

```
#!/usr/bin/env python3
"""
analyzer.py — 数据传输异常分析引擎。

6 条风险检测规则：
R1: futex 阻塞 > 1000ms      → HIGH 告警 (goroutine 饥饿)
R2: read 大小 > 1MB          → HIGH 告警 (异常大块读取)
R3: HTTP socket fd != 1/2/3  → MEDIUM 告警 (可能非标准端口)
R4: write fd 为负或 > 1023   → HIGH 告警 (非标准 fd)
R5: mmap 大小 < 4096         → LOW 告警 (碎片化映射)
R6: 访问敏感路径 /proc/self → CRITICAL 告警
"""

import json, argparse
from dataclasses import dataclass

ALERT_THRESHOLDS = {
    "futex_dur_ms": 1000,
    "read_size_kb": 1024,
    "mmap_size_kb": 4,
}

RISK_LEVELS = {"HIGH": 3, "MEDIUM": 2, "LOW": 1, "CRITICAL": 4}

@dataclass
class Alert:
    ts_ns: int; tid: int; type: str; risk: str; message: str; detail: dict

def detect_anomalies(events: list) -> list:
    alerts = []
    for ev in events:
        etype = ev.get("type", "")
        dur_ms = ev.get("dur_us", 0) / 1000
        size_kb = ev.get("bytes_val", 0) / 1024
        tid = ev.get("tid", 0)
        ts = ev.get("ts_ns", 0)

        if etype == "SyscallEvent" and ev.get("name") == "futex":
            if dur_ms > ALERT_THRESHOLDS["futex_dur_ms"]:
                alerts.append(Alert(ts, tid, "futex_block", "HIGH",
                    f"futex 阻塞 {dur_ms:.0f}ms (线程同步等待) ",
                    {"duration_us": ev["dur_us"], "duration_ms": dur_ms}))

        elif etype == "SyscallEvent" and ev.get("name") == "read":
            if size_kb > ALERT_THRESHOLDS["read_size_kb"]:
                alerts.append(Alert(ts, tid, "read_oversize", "HIGH",
                    f"read 大小 {size_kb:.0f}KB (异常大块读取) ",
                    {"bytes": ev["bytes_val"]}))

    return sorted(alerts, key=lambda a: -RISK_LEVELS.get(a.risk, 0))

def main():
```

```

ap = argparse.ArgumentParser()
ap.add_argument("events", nargs="?", default="trace_events.jsonl")
ap.add_argument("-o", "--output", default="anomaly_report.json")
args = ap.parse_args()
events = [json.loads(l) for l in open(args.events)]
alerts = detect_anomalies(events)
by_risk = {"high": 0, "medium": 0, "low": 0, "critical": 0}
for a in alerts:
    by_risk[a.risk.lower()] += 1
result = {"generated_at": "...", "total_events": len(events),
          "total_alerts": len(alerts),
          "alerts_by_risk": by_risk,
          "top_alerts": alerts[:10]}
with open(args.output, "w") as f:
    json.dump(result, f, indent=2, default=str, ensure_ascii=False)
print(f"Done: {len(alerts)} alerts -> {args.output}")

if __name__ == "__main__":
    main()

```

代码 5.1: call_graph_static.json (符号提取结果)

```

{
  "version": "1.0",
  "binary": "ollama-debug",
  "total_symbols": 4871,
  "layers": {
    "go_cgo_bridge": {"description": "Go → CGO 边界桥接函数", "color": "#e74c3c"},
    "llama_api": {"description": "Llama API 层 (顶层推理接口)", "color":
"#e67e22"},
    "sched_compute": {"description": "GGML 调度与计算层", "color": "#27ae60"}
  },
  "nodes": [
    {"name": "_cgo_8aa400f2462b_Cfunc_llama_decode",
     "layer": "go_cgo_bridge", "addr": "0000000019d1a90"},
    {"name": "llama_decode",
     "layer": "llama_api", "addr": "000000004c82a50"}
  ],
  "edges": [
    {"from": "_cgo_8aa400f2462b_Cfunc_llama_decode",
     "to": "llama_decode", "type": "static", "confidence": "inferred"}
  ]
}

```

代码 5.2: trace_unified.txt (追踪原始输出)

```

@UPROBE@ llama_decode 20560576967386 41062 156
github.com/ollama/ollama/llama.(*SamplingContext).Sample.func1
github.com/ollama/ollama/llama._Cfunc_common_sampler_csampler.abi0

```

```
runtime.cgocall
_cgo_8aa400f2462b_Cfunc_common_sampler_csampl
@END@
@SYSCALL@ read 20560577237885 41062 bytes=512 dur=1
@END@
@SYSCALL@ read 20560577971806 41079 bytes=32768 dur=3
@END@
@SYSCALL@ futex 20584073844710 45625 dur=7912848
@END@
@SYSCALL@ futex 20584073980911 45627 dur=7913095
@END@
```

代码 5.3: llama_folded.txt (折叠栈)

```
_Z21common_sampler_sample;1043;runtime.goexit.abi0
;github.com/ollama/ollama/runner/llamarunner.Execute.gowrap2
;...;github.com/ollama/ollama/llama._Cfunc_common_sampler_csampl.abi0
;runtime.cgocall;_cgo_8aa400f2462b_Cfunc_common_sampler_csampl 1
common_sampler_csampl;1066;...;runtime.cgocall
;_cgo_8aa400f2462b_Cfunc_common_sampler_csampl 1
llama_decode;1423;runtime.goexit.abi0;...;_cgo_8aa400f2462b_Cfunc_llama_decode 1
```

代码 5.4: stitched_result.json (缝合结果)

```
{
  "stitched_at": "2026-05-12T17:15:27",
  "total_nodes": 4832,
  "total_static_edges": 52,
  "summary": {"confirmed": 3, "inferred": 11, "conflicting": 0, "unknown": 38},
  "confirmed_edges": [
    {"from": "_cgo_8aa400f2462b_Cfunc_llama_decode",
      "to": "llama_decode",
      "confidence": "confirmed",
      "layer_from": "go_cgo_bridge",
      "layer_to": "llama_api"},
    {"from": "llama_decode",
      "to": "ggml_backend_sched_graph_compute_async",
      "confidence": "confirmed",
      "layer_from": "llama_api",
      "layer_to": "sched_compute"}
  ],
  "inferred_edges": [
    {"from": "_cgoexp_8aa400f2462b_llamarunner_llama_Execute",
      "to": "llama_decode", "confidence": "inferred",
      "layer_from": "unknown", "layer_to": "llama_api"}
  ]
}
```

代码 5.5: anomaly_report.json (异常分析报告)

```
{
  "generated_at": "2026-05-12T17:25:19",
  "summary": {
    "total_events": 1427,
    "total_syscalls": 1267,
    "total_uprobes": 160,
    "total_alerts": 30,
    "alerts_by_type": {"futex_block": 30},
    "alerts_by_risk": {"high": 30}
  },
  "top_alerts": [
    {"ts_ns": 20584108952430, "tid": 45631,
     "type": "futex_block", "risk": "high",
     "message": "futex 阻塞 15234ms (线程同步等待) ",
     "detail": {"duration_us": 15234000, "duration_ms": 15234.0}},
    {"ts_ns": 20584073980911, "tid": 45627,
     "type": "futex_block", "risk": "high",
     "message": "futex 阻塞 7913ms (线程同步等待) ",
     "detail": {"duration_us": 7913095, "duration_ms": 7913.1}}
  ]
}
```

代码 5.6: eval_report.json (缝合算法评估)

```
{
  "evaluated_at": "2026-05-12T17:25:10",
  "metrics": {
    "precision": 1.0,
    "recall": 0.05,
    "recall_with_inferred": 0.40,
    "f1": 0.095,
    "tp": 1, "fp": 0,
    "gt_size": 20,
    "confirmed": 3,
    "inferred": 11
  },
  "ground_truth": {
    ("'_cgo_...Cfunc_llama_decode', 'llama_decode')":
      "[CGO] Go CGO wrapper → llama_decode",
    ("'_llama_decode', 'ggml_backend_sched_graph_compute_async')":
      "[SRC] llama.cpp run.cpp - llama_decode 调用调度异步计算"
  }
}
```

调用树全貌 (文字缩进版)

```
ollama (主进程)
└─ GOCALL.connect_runner port=37521 (tid=62803)
  Llamarunner (子进程)
  └─ RUNNER.accept fd=7 dur=7µs (tid=63343)
    llama_model_load_from_file dur=718.7ms (tid=63348)
    ─ [Iteration × 10] ─
    └─ ggml_backend_sched_graph_compute_async dur=28-37ms
      └─ llama_decode dur=29-38ms
      └─ llama_synchronize dur=1-3µs
      └─ common_sampler_sample_cpp dur=0.9-2.0ms
      └─ common_sampler_csampl dur=0.9-2.1ms
    ─ [syscalls] ─
    └─ read(4KB-1.6MB) × 4600+ 模型权重读取
    └─ write(bytes) × 245 HTTP 响应写入
    └─ futex(wait) × 195 goroutine 调度同步
```

数据来源: bpftrace -o trace_output.txt · 采集时长: 15 秒 · 事件总数: 4785 · 跟踪脚本: trace_unified.bt